

## 4. Model Coxa (cd.)

Zmienne objaśniające zależne od czasu

Ocena dobroci dopasowania

Model regresji Poissona

# Zmienne objaśniające zależne od czasu w modelu Coxa (1)

$$\lambda(t) = \lambda_0(t) \cdot e^{X'\alpha + Z(t)\beta}$$

- ◆ Zmienne objaśniające, których wartości zmieniają się w czasie
  - Zmienne wewnętrzne: mierzalne tylko gdy jednostka pozostaje pod obserwacją; np. wielokrotne pomiary parametru krwi chorego
  - Zmienne zewnętrzne: nie związane z obserwowaną jednostką, o wartościach znanych z góry (np. planowane dawki leku, pora roku, itd.)
- ◆  $e^\beta$  jest ilorazem hazardu związanym ze wzrostem  $Z(t)$  o 1 dla dowolnego  $t$  (nie tylko dla  $t=0$ ), przy ustalonej wartości  $X$

# Zmienne objaśniające zależne od czasu w programach statystycznych

- ◆ Tzw. „counting process input”:

PatID	Start	Stop	Event	$Z_1$	$Z_2$
1	0	3	0	1	4.5
1	3	5	0	1	6
1	5	13	0	1	3
1	13	22	1	1	6

- ◆ *Start* i *stop* mogą być datą lub wartością czasu

- Metoda pozwala na uwzględnienie „opóźnionego rozpoczęcia obserwacji” lub wyłączeń ze zbioru ryzyka

PatID	Start	Stop	Event	$Z_1$	$Z_2$
1	0	3	0	1	4.5
1	4	5	0	1	6
2	5	8	0	1	3
2	8	11	1	1	7

# „Wewnętrzne” zmienne objaśniające zależne od czasu


- ◆ Ich użycie wymaga ostrożności
- ◆ Przykład (hipotetyczny): leczenie białaczki
  - Przeżycie chorego może zależeć od poziomu płytek krwi
  - Załóżmy, że lek podwyższa poziom płytek
  - Po uwzględnieniu poziomu płytek jako zmiennej objaśniającej zależnej od czasu w modelu, efekt leczenia może nie być istotny

# Szacowanie modelu Coxa ze zmiennymi objaśniającymi zależnymi od czasu

$$L(\beta) = \prod_{k=1}^K \frac{e^{\beta' Z_{(k)}(t_{(k)})}}{\sum_{l=1}^n Y_l(t_{(k)}) e^{\beta' Z_l(t_{(k)})}}$$

◆ Konieczna znajomość wartości zmiennych dla wszystkich zaobserwowanych czasów zdarzeń

- potencjalna trudność
  - interpolacja dla zmiennych ciągłych
  - problem dla zmiennych dyskretnych



**Figure 8.2** Computation of the value of a time-dependent variable at intermediate times.

# Ocena dobroci dopasowania modelu (1)

- ◆ Reszty martyngałowe: 
$$M(t) = N(t) - \int_0^t Y(u) \lambda_0(u) e^{\beta^T Z(u)} du$$
- ◆ Przy „counting style input”, kilka reszt dla obserwowanej jednostki:  $M(stop) - M(start)$ 
  - Suma daje resztę całkowitą
- ◆ Wykres reszt martyngałowych (lub opartych na dewiacji) vs.  $Z'(t)\beta$  daje możliwość ogólnej oceny dopasowania modelu
  - np. obserwacji odstających

# Ocena dobroci dopasowania modelu (2)

- ◆ Funkcja przeżycia dla jednostki  $i$  na podstawie modelu:

$$S_i(t) = \exp \left\{ - \int_0^t \exp(\beta^T Z(u)) \lambda_0(u) du \right\}$$

- Może zależeć od przyszłych (nieznanych) wartości  $Z(t)$

- ◆ Rozważmy p-stwo przeżycia „krótkiego” przedziału:

$$\begin{aligned} P(T_i^* \geq t+h \mid T_i^* \geq t) &= S_i(t+h) / S_i(t) = \\ &= \frac{\exp \left\{ - \int_0^{t+h} \exp(\beta^T Z(u)) \lambda_0(u) du \right\}}{\exp \left\{ - \int_0^t \exp(\beta^T Z(u)) \lambda_0(u) du \right\}} \approx \frac{\exp \left\{ - \exp(\beta^T Z(t)) \int_0^{t+h} \lambda_0(u) du \right\}}{\exp \left\{ - \exp(\beta^T Z(t)) \int_0^t \lambda_0(u) du \right\}} = \\ &= \exp \{ (-\Lambda_0(t+h) + \Lambda_0(t)) \exp(\beta^T Z(t)) \} \end{aligned}$$

# Ocena dobroci dopasowania modelu (3)

- ◆ 1-  $P(T^* \geq t+h | T^* \geq t)$  to prawdopodobieństwo zdarzenia w  $(t, t+h)$
- ◆ Możemy oszacować wartości  $P(T^* \geq t+h | T^* \geq t)$  na podstawie oszacowania  $\beta$  i  $\Lambda_0 \dots$
- ◆ ... i użyć ich do obliczenia oczekiwanej liczby zdarzeń.
- ◆ Porównanie z obserwowaną liczbą zdarzeń w kolejnych przedziałach daje możliwość oceny dopasowania modelu do danych.



# Ocena formy funkcjonalnej zmiennej objaśniającej zależnej od czasu (1)

- ◆ „Wygładzony” wykres reszt martyngałowych dla „pustego” modelu nie działa
  - kilka reszt dla jednostki – wiele reszt w okolicach 0
  - użycie reszty całkowitej – ale dla jakiej wartości zmiennej?
  - możliwość obciążenia estymacji na podstawie wykresu




FIGURE 5.17: *Sequential PBC data, null model martingale residuals*

# Ocena formy funkcjonalnej zmiennej objaśniającej zależnej od czasu (2)

- Możliwe użycie modelu Poissona z gładką funkcją zmiennej lub zastosowanie spline'ów




FIGURE 5.18: *Sequential PBC data, smoothing spline fit*




FIGURE 5.19: *Sequential PBC data, protocol visits only*

# „Wewnętrzne” zmienne objaśniające zależne od czasu: przykład (1)

- ◆ Przykład (hipotetyczny): leczenie marskości wątroby
  - logarytm bilirubiny na początku próby klinicznej

**Table 8.3** *Survival times of 12 patients in a study on cirrhosis of the liver.*

Patient	Time	Status	Treat	Age	Lbr
1	281	1	0	46	3.2
2	604	0	0	57	3.1
3	457	1	0	56	2.2
4	384	1	0	65	3.9
5	341	0	0	73	2.8
6	842	1	0	64	2.4
7	1514	1	1	69	2.4
8	182	0	1	62	2.4
9	1121	1	1	71	2.5
10	1411	0	1	69	2.3
11	814	1	1	77	3.8
12	1071	1	1	58	3.1

**Table 8.5** *Values of  $-2\log \hat{L}$  for models without a time-dependent variable.*

Terms in model	$-2\log \hat{L}$
null model	25.121
Age	22.135
Lbr	21.662
Age, Lbr	18.475

◆ *Age + Lbr + Treat.*

LRT = 5.182 (p=0.023)

$\beta_{Treat} = -3.052$

# „Wewnętrzne” zmienne objaśniające zależne od czasu: przykład (2)

## ♦ Logarytm bilirubiny zależny od czasu

Patient	Time	Status	Treat	Age	Lbr
1	281	1	0	46	3.2
2	604	0	0	57	3.1
3	457	1	0	56	2.2

Patient	Follow-up time	Log(bilirubin)
1	47	3.8
	184	4.9
	251	5.0
2	94	2.9
	187	3.1
	321	3.2
3	61	2.8
	97	2.9
	142	3.2
	359	3.4
	440	3.8

**Table 8.6** Values of  $-2 \log \hat{L}$  for models with a time-dependent variable.

Terms in model	$-2 \log \hat{L}$
null model	25.121
Age	22.135
Lbrt	12.053
Age, Lbrt	11.145

### ♦ $Lbr + Treat$ .

$$LRT = 12.053 - 10.676 = 1.377 \quad (p=0.241)$$

$$\beta_{Lbr} = 3.605, \quad \beta_{Treat} = -1.479$$

- ♦ Jeśli leczenie zmienia poziom bilirubiny, włączenie  $Lbr$  do modelu uwzględnia efekt leczenia

# „Wewnętrzne” zmienne objaśniające zależne od czasu: przykład (3)

## ♦ Logarytm bilirubiny zależny od czasu

**Table 8.7** *Estimated baseline cumulative hazard function,  $\tilde{H}_0(t)$ , for the cirrhosis study.*

Follow-up time ( $t$ )	$\tilde{H}_0(t)$
0	0.000
281	$0.009 \times 10^{-6}$
384	$0.012 \times 10^{-6}$
457	$0.541 \times 10^{-6}$
814	$0.908 \times 10^{-6}$
842	$1.577 \times 10^{-6}$
1071	$3.318 \times 10^{-6}$
1121	$6.007 \times 10^{-6}$
1514	$6.053 \times 10^{-6}$

**Table 8.8** *Approximate conditional survival probabilities for patients 1 and 7.*

Time interval	$\tilde{P}_1(t, t+h)$	$\tilde{P}_7(t, t+h)$
0–	0.999	1.000
360–	0.000	0.994
720–	0.000	0.969
1080–	0.000	0.457
1440–	0.045	0.364

Interval	Expected	Observed	
0-359	0.02	1	
360-719	2.46	2	♦ Expected>observed
720-1079	5.64	3	♦ Mała liczebność próbki
1080-1439	6.53	1	
1440-1514	3.16	1	

# Model regresji Poissona (1)

- ◆ Dla współczynników intensywności zdarzeń
- ◆ Szacowanie wymaga obserwacji występowania zdarzeń w czasie
- ◆ Najbardziej podstawowy estymator (*incidence density, ID*):

$$ID = \frac{I}{PT} = \frac{\text{no. of new cases in the calendar period } (t_0, t_1)}{\text{accrued population time}}$$

- ◆ *ID* jest wyznaczany z danych *zgrupowanych*
  - zliczenia zdarzeń

# Model regresji Poissona (2)

- ◆ Współczynnik intensywności  $\lambda$  dla grupy 1 i  $\lambda_0$  dla grupy 0
- ◆ Rozważmy *iloraz współczynników (incidence rate ratio)*

$$\text{IRR} = \lambda / \lambda_0$$

który można wyrazić jako

$$\lambda = \lambda_0 \cdot \theta$$

gdzie  $\theta = \text{IRR}$

- ◆ Równoważnie:

$$\ln \lambda = \ln \lambda_0 + \ln \theta$$

lub, kładąc  $\beta_0 = \ln \lambda_0$ ,  $\beta = \ln \theta$ , i  $Z=1$  (0) dla grupy 1 (0)

$$\ln \lambda = \beta_0 + \beta \cdot Z$$

# Model regresji Poissona (2)

- ◆ Model

$$\ln \lambda = \beta_0 + \beta \cdot Z$$

jest modelem regresji dla współczynników intensywności

- ◆ Parametry są szacowane na podstawie zliczeń zdarzeń i osobo-czasu
  - zakłada się, że zdarzenia mają rozkład Poissona ze średnią  $\lambda$
  - przykład *uogólnionego modelu liniowego*



# Model PH i model regresji Poissona (1)

- ♦ Zauważmy, że

$$\ln \lambda = \beta_0 + \beta \cdot Z$$

można zapisać jako

$$\lambda = e^{\beta_0 + \beta \cdot Z} = \lambda_0 e^{\beta \cdot Z}$$

- ♦ Załóżmy, że współczynniki intensywności zmieniają się w przedziałach czasu indeksowanych przy pomocy  $t$

$$\lambda_t = e^{\beta_{0t} + \beta \cdot Z} = \lambda_{0t} e^{\beta \cdot Z}$$

lub

$$\lambda(t) = \lambda_0(t) e^{\beta \cdot Z}$$

- ♦ Bardzo przypomina model...

# Model PH i model regresji Poissona (2)

- ◆ Oba modele mają podobną formę

$$\ln \text{rate} = \beta_0 + \beta \cdot Z$$

- ◆ Regresja Poissona wymaga zgrupowanych danych w przedziałach czasu do oszacowania modelu
  - konieczne szacowanie bazowych współczynników intensywności  $\lambda_{0t}$
  - mała liczebność próbki stanowi problem (mała precyzja oszacowań)
- ◆ Model PH używa danych indywidualnych (nieskończenie wąskie przedziały czasu)
  - bazowa funkcja hazardu nie jest szacowana
  - mniejsze wymagania dotyczące liczebności próbki